



# 矩阵论笔记3

张天阳\*

University of Chinese Academy of Science

December 11, 2017

---

\*E-mail: [zhangtianyang17@mails.ucas.edu.cn](mailto:zhangtianyang17@mails.ucas.edu.cn)

# Contents

<b>I</b>	<b>矩阵分解</b>	<b>2</b>
1	Gauss消去法:	2
2	三角分解:	2
2.1	Doolittle分解 . . . . .	3
2.2	Cholesky分解 . . . . .	3
3	分块矩阵求逆	3
3.1	行变换解析 . . . . .	3
3.2	分块矩阵求逆 . . . . .	3
4	Givens矩阵 (旋转矩阵) 对向量操作:	4
4.1	二维例子 . . . . .	4
4.2	高维时的旋转矩阵 . . . . .	4
4.3	旋转定理 . . . . .	4
5	Householder变换 (初等反射变换)	5
5.1	Householder矩阵定义与推导 . . . . .	5
5.2	Householder变换性质 . . . . .	5
6	矩阵的QR分解	6
6.1	定义 . . . . .	6
6.2	方法一: Schmidt正交化方法 . . . . .	6
6.3	方法二: Givens矩阵变换得到QR分解 . . . . .	7
6.4	方法三: 利用Householder变换得到QR分解 . . . . .	7
7	矩阵的满秩分解: FG分解	8
8	奇异值分解	8
8.1	前序知识与回顾 . . . . .	8
8.1.1	谱分解 . . . . .	8
8.2	奇异值分解 . . . . .	8
8.2.1	思路与引理: 其与前序的方法不同也不要求 $A$ 是非奇异 . . . . .	8
8.2.2	奇异值分解证明 . . . . .	9
8.2.3	用 $A^T A$ 奇异值分解使用方法 . . . . .	10
8.2.4	用 $AA^T$ 奇异值分解使用方法 . . . . .	10
8.3	奇异值分解的定理与应用 . . . . .	11
8.3.1	定理 . . . . .	11
8.3.2	应用 . . . . .	11
<b>II</b>	<b>矩阵的特征值的重要性质:</b>	<b>11</b>

## Part I

## 矩阵分解

## 1 Gauss消去法:

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

首先行变换左乘，列变换右乘

每次高斯消去都是左乘第k次变换的矩阵 $L_k$ :

$$L_k = I - \mathbf{l}_k \mathbf{e}^T \quad (1)$$

$$\mathbf{l}_k = [0_1, 0_2, 0_3, \dots, 0_k, c_{k+1}, c_{k+2}, c_{k+3}, \dots, c_n]^T, \quad 0_k \text{ means } k\text{th } 0 \quad (2)$$

因为每次高斯消去法都是将第k列消去，所以就是减去一个第k行从 $a_{kk}$ 开始往下都是 $\frac{a_{k(k+i)}}{a_{kk}}$ 乘以第k行再减去自己，于是相当于乘以：

$$\mathbf{l}_k \mathbf{e}^T = \begin{bmatrix} 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \cdots & \vdots & \cdots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \cdots & 0_{k,k} & \cdots & \vdots \\ 0 & \cdots & \frac{a_{k,(k+1)}}{a_{k,k}} & \cdots & 0 \\ \vdots & \cdots & \vdots & \cdots & \vdots \\ 0 & \cdots & \frac{a_{k,(n)}}{a_{k,k}} & \cdots & 0 \end{bmatrix} \quad (3)$$

$$L = L_1 L_2 \dots L_n = I - \mathbf{l}_1 \mathbf{e}^T - \mathbf{l}_2 \mathbf{e}^T - \dots - \mathbf{l}_{n-1} \mathbf{e}^T \quad (4)$$

则上三角矩阵 $LA$ 可得。

## 2 三角分解:

$$A = LU \quad (5)$$

先求出Gauss消去法的 $L$ 。

矩阵分解中 $L$ 是Gauss中的 $L^{-1}$

$$L = L_1 L_2 \dots L_n = I + \mathbf{l}_1 \mathbf{e}^T + \mathbf{l}_2 \mathbf{e}^T + \dots + \mathbf{l}_{n-1} \mathbf{e}^T \quad (6)$$

而 $U$ 就是Gauss消去法所得到的上三角矩阵。

## 2.1 Doolittle分解

即将矩阵分解为 $LDU$ 其中 $U$ 为对角值为1的矩阵，而 $D$ 则是对角矩阵，其实就是讲矩阵分解为 $LU$ 之后将 $U$ 逐行提取公因式，写作 $D$ 。

而 $LU$ 则称为Doolittle分解。

## 2.2 Cholesky分解

Cholesky分解是将是对称正定矩阵 $A$ 分解为

$$A = G^T G \quad (7)$$

其是现将矩阵分解为： $LDU$ 形式：

可得

$$G = L\sqrt{D} \quad (8)$$

即 $D$ 的每个对角线的元素（ $D$ 为对角矩阵）都开跟号

## 3 分块矩阵求逆

### 3.1 行变换解析

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix} = \begin{bmatrix} A & B \\ -CA^{-1}A + C & -CA^{-1}B + D \end{bmatrix}, \text{ Gauss Method} \quad (9)$$

相当于左乘（行变换），注：分块矩阵乘法是原来在左边的乘完还在左边。

$$X = \begin{bmatrix} 1 & & & & & & \\ & 1 & & & & & \\ & & 1 & & & & \\ & & & \ddots & & & \\ 0 & \cdots & x_{ij} & \cdots & 1 & \cdots & 0 \\ & & & & & \ddots & \\ & & & & & & 1 \end{bmatrix}, \text{ only } X_{ij} = x_{ij}$$

$$X = I + x_{ij}e_i e_j^T$$

这样的变换矩阵 $X$ ，左乘 $A$ ， $XA$ 相当于将 $A$ 的第 $i$ 行加上第 $j$ 列乘以 $x_{ij}$

解释上面为什么是第一行左乘 $CA^{-1}$ 在加到第二行，因为高斯消去法需要让第二行第一个元素为 $O$ 所以要将第一行乘以（左乘是因为行变换是左乘， $CA^{-1}$ 是因为 $A^{-1}C$ 的话消不掉 $A$ 会变为 $A^{-1}CA$ ）。该行都同时乘以 $A$ 的话是左乘，而该列都同时乘以 $A$ 的话是右乘。

### 3.2 分块矩阵求逆

对下面分块矩阵求逆：应该先拓展，然后将其行变换为单位阵然后拓展阵自然变成它的逆。

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix} \Rightarrow \begin{bmatrix} A & B & I & O \\ C & D & O & I \end{bmatrix}$$

下面的式子第二行应该归一化，因为不然化三角时会让式子很长。

$$\begin{aligned}
 \begin{bmatrix} A & B & I & O \\ C & D & O & I \end{bmatrix} &= \begin{bmatrix} A & B & I & O \\ -CA^{-1}A + C & -CA^{-1}B + D & O - CA^{-1}B & I - CA^{-1}B \end{bmatrix} \\
 &= \begin{bmatrix} A & B & I & O \\ O & I & -(-CA^{-1}B + D)^{-1}CA^{-1}B & (-CA^{-1}B + D)^{-1}(I - CA^{-1}B) \end{bmatrix} \\
 &= \begin{bmatrix} A & O & I + B^{-1}(-CA^{-1}B + D)^{-1}CA^{-1}B & -B^{-1}(-CA^{-1}B + D)^{-1} \\ O & I & -(-CA^{-1}B + D)^{-1}CA^{-1}B & (-CA^{-1}B + D)^{-1}(I - CA^{-1}B) \end{bmatrix} \\
 &= \begin{bmatrix} I & O & A^{-1}[I + B^{-1}(D - CA^{-1}B)^{-1}CA^{-1}B] & -A^{-1}[B^{-1}(D - CA^{-1}B)^{-1}] \\ O & I & -(D - CA^{-1}B)^{-1}CA^{-1}B & (D - CA^{-1}B)^{-1}(I - CA^{-1}B) \end{bmatrix}
 \end{aligned}$$

所以其逆为：

$$= \begin{bmatrix} A^{-1}[I + B^{-1}(D - CA^{-1}B)^{-1}CA^{-1}B] & -A^{-1}[B^{-1}(D - CA^{-1}B)^{-1}] \\ -(D - CA^{-1}B)^{-1}CA^{-1}B & (D - CA^{-1}B)^{-1}(I - CA^{-1}B) \end{bmatrix}$$

## 4 Givens矩阵（旋转矩阵）对向量操作：

### 4.1 二维例子

顺时针旋转  $\theta$  角(在极坐标系中角度增加  $-\theta$ )后空间中的向量  $\mathbf{x}$  为：因为极坐标中的  $\mathbf{x}$  为：

$$x_1 = r \cdot \cos(\varphi), \quad x_2 = r \cdot \sin(\varphi)$$

$$\begin{bmatrix} \cos(\theta) & \sin(\theta) \\ -\sin(\theta) & \cos(\theta) \end{bmatrix} \mathbf{x} = T_{12} \mathbf{x} \quad (10)$$

用  $c$  表示  $\cos(\theta)$ ， $s$  表示  $\sin(\theta)$

### 4.2 高维时的旋转矩阵

高维时候其仍然一次只旋转两个维度，因为任意两个维度可以组成一个平面，然后在该平面上有上面二维的结论，故当旋转将  $i$  向着  $j$  旋转时：

$$\mathbf{x} = [x_1, x_2, \dots, x_n]^T, \quad \mathbf{y} = T_{ij} \mathbf{x} = [y_1, y_2, \dots, y_n]^T$$

$$\begin{cases} y_i = cx_i + sx_j \\ y_j = -sx_i + cx_j \\ y_k = x_k, \quad (if \ k \neq i, j) \end{cases}$$

$T_{ij}$  被叫做GIVENS矩阵

### 4.3 旋转定理

1. 存在有限个Givens矩阵的乘积，记作  $T$  可以使  $T\mathbf{x} = |\mathbf{x}| \mathbf{e}_1$ ， $\mathbf{e}_i$  为仅仅只有第  $i$  维为1的单位列向量。
2. 同时也存在有限个Givens矩阵的乘积，记作  $T$  可以使  $T\mathbf{x} = |\mathbf{x}| \mathbf{z}$ ， $\mathbf{z}$  为任意单位向量

## 5 Householder变换（初等反射变换）

### 5.1 Householder矩阵定义与推导

$$H = I - 2\mathbf{u}\mathbf{u}^T \quad (11)$$

$\mathbf{u}$ 是 $\mathbf{x}$ 要对称的超平面的法向量（单位向量，方向垂直于超平面）， $\mu$ 为图上与法向量方向相同的向量,推导:




Figure 1: 反射变换图

According to the defination :  $H\mathbf{x} = \mathbf{y}$

$$\mathbf{x} - \mathbf{y} = 2\mu$$

$$\Rightarrow (I - H)\mathbf{x} = 2\mu$$

Becaus  $\mathbf{u}^T \mathbf{x} = \|\mu\|$ , So  $\mathbf{u}\mathbf{u}^T \mathbf{x} = \mu$

$$\Rightarrow H = I - 2\mathbf{u}\mathbf{u}^T$$

### 5.2 Householder变换性质

1. H矩阵性质:

$$\begin{cases} H^T = H, & (\lambda \text{ is real number}) \\ H^T H = I, & (\text{Thus } H^T = H^{-1}), \text{ } H \text{ is Orthogonal Matrix} \\ H^2 = I \\ H^{-1} = H \\ |H| = -1 \end{cases} \quad (12)$$

2. 对于任意 $\mathbf{x} \in R^n$ 机器单位列向量 $\mathbf{z} \in R^n$ 存在Householder矩阵H, 使得 $H\mathbf{x} = |\mathbf{x}|\mathbf{z}$ ,  $\mathbf{z}$ 为任意单位向量。

3. 任意Givens矩阵（旋转矩阵）可以由两个Householder矩阵相乘得到，但是Householder矩阵不可以由若干Givens矩阵相乘得到，因为 $|G| = 1, |H| = -1$ 。

## 6 矩阵的QR分解

### 6.1 定义

矩阵的QR分解是将满秩矩阵 $A$ 分解为 $A = QR$ 其中 $Q$ 为正交矩阵（酉矩阵 $Q^T Q = I$ ），而 $R$ 则为上三角矩阵。

### 6.2 方法一：Schmidt正交化方法

因为 $A$ 为满秩矩阵所以 $A$ 的所有列是线性无关的，所以其所有列可以正交化得到一组正交基，将正交化的列放在一起便成了正交矩阵 $B$ 。具体过程如下：

1. 对于矩阵 $A = (\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n)$ 作正交化：Schmidt正交化过程可以想象一个下三角矩阵，其每个下标是 $k_{ij}$ 而其第 $n$ 行（每一行）都是 $\mathbf{b}_n$ 对于 $\mathbf{a}_n$ 的线性组合，而每行的 $\mathbf{b}_k$ 表示列的下标。

$C$ 的行为下面的列、第一行、第二行.....第 $n$ 行

$$\begin{aligned}\mathbf{a}_1 &= \mathbf{b}_1 \\ \mathbf{a}_2 &= k_{21}\mathbf{b}_1 + \mathbf{b}_2 \\ \mathbf{a}_3 &= k_{31}\mathbf{b}_1 + k_{32}\mathbf{b}_2 + \mathbf{b}_3 \\ &\dots \\ \mathbf{a}_n &= k_{n1}\mathbf{b}_1 + k_{n2}\mathbf{b}_2 + \dots + \mathbf{b}_n\end{aligned}$$

几何意义想象一下，第 $k$ 行为 $\mathbf{a}_k$ 在 $\mathbf{b}_1, \dots, \mathbf{b}_k$ 的空间内的坐标，其中 $k_{ij}$ 为第 $j$ 个坐标的值为： $\mathbf{a}_k$ 在 $\mathbf{b}_j$ 上的投影乘以单位化的 $\mathbf{b}_j$ 即：

2. 其中 $\mathbf{a}_k$ 是已知要被分解的矩阵 $A$ 的第 $k$ 列，而 $k_{ij}$ 为：

$$k_{ij} = \frac{(\mathbf{a}_i, \mathbf{b}_j)}{(\mathbf{b}_j, \mathbf{b}_j)} \quad (13)$$

所以 $k_{ii} = 1$ 所以对角线上的 $k$ 为1。于是可以得到 $\mathbf{b}_i$ 的公式：

$$\begin{aligned}\mathbf{b}_1 &= \mathbf{a}_1 \\ \mathbf{b}_2 &= \mathbf{a}_2 - k_{21}\mathbf{b}_1 \\ \mathbf{b}_3 &= \mathbf{a}_3 - k_{31}\mathbf{b}_1 - k_{32}\mathbf{b}_2 \\ &\dots \\ \mathbf{b}_n &= \mathbf{a}_n - k_{n1}\mathbf{b}_1 - k_{n2}\mathbf{b}_2 - \dots - k_{nn-1}\mathbf{b}_{n-1}\end{aligned}$$

所以 $A = BC$ ， $C$ 为上面所述。

我们求出所有 $\mathbf{b}_i$ 之后我们将其对角化之后便是 $Q$  而对角化需要乘以对角矩阵：

$\text{diag}(1/\|\mathbf{b}_1\|, 1/\|\mathbf{b}_2\|, \dots, 1/\|\mathbf{b}_n\|)$

矩阵 $\text{diag}(\|\mathbf{b}_1\|, \|\mathbf{b}_2\|, \dots, \|\mathbf{b}_n\|)C$ 即为 $R$

3. 综上所述可得 $A = QR$

### 6.3 方法二: Givens矩阵变换得到QR分解

Givens变换 $T_1$ 可以使得矩阵 $A = (\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n)$ 的第一列变为 $[\|\mathbf{a}_1\|, 0, 0, \dots, 0]^T$ , 于是将矩阵A乘以 $T_1$ 可以得到: ( $T_1$ 变换时最接近A, 即将A用许多Givens变换变为上三角矩阵(R)时 $T_1$ 为最接近A的那个左乘矩阵)

$$T_1 A = \begin{bmatrix} \|\mathbf{a}_1\| & * & \dots & * \\ 0 & & & \\ \vdots & & A_1 & \\ 0 & & & \end{bmatrix}_{n \times n} \quad (14)$$

再对 $A_1$ 的第一列进行Givens变换 $T_2 A_1$

$$T_2 A_1 = \begin{bmatrix} \|\mathbf{a}_1^{(1)}\| & * & \dots & * \\ 0 & & & \\ \vdots & & A_2 & \\ 0 & & & \end{bmatrix}_{(n-1) \times (n-1)} \quad (15)$$

以此类推:

$$T = \begin{bmatrix} I_{n-2} & O \\ O & T_{n-1} \end{bmatrix} \begin{bmatrix} I_{n-3} & O \\ O & T_{n-2} \end{bmatrix} \dots \begin{bmatrix} 1 & O \\ O & T_2 \end{bmatrix} T_1 \quad (16)$$

$$TA = R \quad (17)$$

于是:

$$A = T^{-1}R = QR \quad (18)$$

### 6.4 方法三: 利用Householder变换得到QR分解

思路与用Givens矩阵得到QR分解一样也是先用变换矩阵T得到上三角矩阵R

同样先对 $A = (\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n)$ 的第一列找到变换矩阵 $H_1$ 使得 $\mathbf{a}_1$ 变为:  $\|\mathbf{a}_1\|\mathbf{e}_1$ , 然后以此类推。

$$T = \begin{bmatrix} I_{n-2} & O \\ O & H_{n-1} \end{bmatrix} \begin{bmatrix} I_{n-3} & O \\ O & H_{n-2} \end{bmatrix} \dots \begin{bmatrix} 1 & O \\ O & T_2 \end{bmatrix} T_1 \quad (19)$$

$$TA = R \quad (20)$$

于是:

$$A = T^{-1}R = T^T R = QR \quad (21)$$

对于H的求解方法:  $H = I - 2\mathbf{u}\mathbf{u}^T$ 而对于 $\mathbf{u}$ 的求解:

$$\begin{aligned} \boldsymbol{\mu} &= \mathbf{a}_1 - \|\mathbf{a}_1\|\mathbf{e}_1 \\ \mathbf{u} &= \frac{\boldsymbol{\mu}}{\|\boldsymbol{\mu}\|} \end{aligned}$$



## 7 矩阵的满秩分解：FG分解

用于分解一些不是方阵（非方阵）的矩阵。

分解方法：

1. 用高斯消去法将待分解的矩阵转换为Hermite标准型（不是Hermite矩阵）  
Hermite标准型：每一行第一个非零元素为1，前r行为非零行。
2. 取A的每个Hermite（标准型）对应的首1列（行的第一个非零的元素也就是1对应的列）组成F，而Hermite标准型的所有非零行构成G。

满秩分解重要性质： $A_r^{m \times n} = F_r^{m \times r} G_r^{r \times n}$

## 8 奇异值分解

### 8.1 前序知识与回顾

#### 8.1.1 谱分解

如果A是实对称矩阵那么A满足：

$$Q^T A Q = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n), \text{ 其中 } Q \text{ 为正交矩阵} \quad (22)$$

如果A不是实数对称矩阵，但是A仍然非奇异，那么A可以分解为：

$$P^T A Q = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n), \text{ 其中 } P \text{ 与 } Q \text{ 为正交矩阵} \quad (23)$$

而奇异值分解为无任何条件的矩阵A可以分解为：

$$U^H A V = \begin{bmatrix} \Sigma_{r \times r} & O \\ O & O \end{bmatrix} \quad (24)$$

即：V是左乘A的所以对于运算时用 $A^T A$ 还是 $A A^T$ ，可以先求出V或者U

$$A = U \begin{bmatrix} \Sigma_{r \times r} & O \\ O & O \end{bmatrix} V^H \quad (25)$$

### 8.2 奇异值分解

#### 8.2.1 思路与引理：其与前序的方法不同也不要求A是非奇异

1. 由于A虽然不是实对称矩阵，A为 $\forall A \in \mathbf{C}^{m \times n}$ ，但是 $A^T A$ 是Hermite矩阵（对称矩阵）所以其是半正定的。
2. 且 $\text{rank}(A^T A) = \text{rank}(A)$
3.  $A^T A = O$ 的冲要条件是 $A = O$

4. 对 $A^T A$ 进行谱分解可以得到:  $V^T A^T A V = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$ , 其中 $V$ 为正交(酉)矩阵其中其中 $\lambda_1, \lambda_2, \dots, \lambda_n$ 为矩阵 $A^T A$ 的特征值, 而 $\sigma_i = \sqrt{\lambda_i}$ , ( $i = 1, 2, \dots, n$ )被称为其奇异值。  
对于 $V$ 取其每一列 $\mathbf{v}_i$ 可以发现:

$$A^T A \mathbf{v}_i = \mathbf{v}_i \lambda_i \quad (26)$$

所以求出每个 $\lambda_i$ 对应的特征向量 $\xi_i$ , (零特征值的也求, 重根也求, 求 $n$ 个嘛) (每个特征值只求一个即可), 可得 $V = (\xi_1, \xi_2, \dots, \xi_n)$ ,

### 8.2.2 奇异值分解证明

1. 上一小节得到的矩阵 $B = A^T A$ 的特征值对角矩阵 $\text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$ 其中有 $r$ 个非零项, 所以将其写为:

$$\text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n) = \begin{bmatrix} \Sigma_{r \times r}^2 & O \\ O & O \end{bmatrix} \quad (27)$$

2. 求出每个 $\lambda_i$ 对应的特征向量, (零特征值的也求, 重根也求, 求 $n$ 个嘛) (每个特征值只求一个即可), 可得 $(\xi_1, \xi_2, \dots, \xi_n)$ , 由于谱分解的定律我们可以得到:

$$\begin{aligned} V^H A^T A V &= \begin{bmatrix} \Sigma_{r \times r}^2 & O \\ O & O \end{bmatrix} \\ V &= (\xi_1, \xi_2, \dots, \xi_n) \end{aligned}$$

取 $V_{n \times n}$ 的前 $r$ 列构成矩阵 $V_1$ 可以得到:  $V = [V_1 (n \times r) | V_2 (n \times n - r)]$   
可知:

$$V_1^H A^T A V_1 = \Sigma_{(r \times r)}^2 \quad (28)$$

3. 可以将上式写成:

$$\begin{aligned} A^T A &= V_1 \Sigma^2 V_1^H, \text{ 因为 } V \text{ 正交} \\ &\Rightarrow (A V_1 \Sigma^{-1})^H (A V_1 \Sigma^{-1}) = I \end{aligned}$$

所以: 令  $U_1 = A V_1 \Sigma^{-1}$  可得

$$\begin{cases} U_1^T U_1 = I, \text{ 得到 } U_1 \text{ 为正交矩阵} \\ U_1^H A V_1 = \Sigma \end{cases} \quad (29)$$

让 $U = [U_1 | U_2]$ 其中 $U_2$ 为随意列只要保证 $U$ 正交即可: 因为:

$$\begin{aligned} U^H A V &= [U_1 | U_2]^H A [V_1 | V_2] \\ &= [U_1^H A | U_2^H A]^H [V_1 | V_2] \\ &= \begin{bmatrix} U_1^H A V_1 & U_1^H A V_2 \\ U_2^H A V_1 & U_2^H A V_2 \end{bmatrix} \end{aligned}$$

又因为

$$\begin{aligned}
 AV_1 = U_1 \Sigma &\Rightarrow U_2^H AV_1 = U_2^H U_1 \Sigma = O, \quad (U_2, U_1 \text{正交}) \\
 AV_2 &= O \\
 U_1^H AV_1 &= \Sigma \\
 \Rightarrow U^H AV &= \begin{bmatrix} \Sigma & O \\ O & O \end{bmatrix}
 \end{aligned}$$

### 8.2.3 用 $A^T A$ 奇异值分解使用方法

记住 $V A^T A V$ 在一起, 即 $V$ 为 $n$ 阶方阵

1. 得到的矩阵 $B = A^T A$ 的特征值对角矩阵 $\text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$ 其中有 $r$ 个非零项, 所以将其写为:

$$\text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n) = \begin{bmatrix} \Sigma_{r \times r}^2 & O \\ O & O \end{bmatrix} \quad (30)$$

2. 求出每个 $\lambda_i$ 对应的特征向量,(零特征值的也求, 重根也求, 求 $n$ 个嘛)(每个特征值只求一个即可), 可得 $(\xi_1, \xi_2, \dots, \xi_n)$ , 由于谱分解的定律我们可以得到:

$$\begin{aligned}
 V^H A^T A V &= \begin{bmatrix} \Sigma_{r \times r}^2 & O \\ O & O \end{bmatrix} \\
 V &= (\xi_1, \xi_2, \dots, \xi_n)
 \end{aligned}$$

取 $V_{n \times n}$ 的前 $r$ 列构成矩阵 $V_1$ 可以得到:  $V = [V_{1(n \times r)} | V_{2(n \times n-r)}]$

3. 令 $U_1 = AV_1 \Sigma^{-1}$ (用 $U_1^H AV = \Sigma$ 记忆。)可得 $U = [U_1 | U_2]$ 让其中 $U_2$ 为随意列只要保证 $U$ 正交即可:
4. 则:

$$U^H AV = \begin{bmatrix} \Sigma & O \\ O & O \end{bmatrix} \quad (31)$$

### 8.2.4 用 $AA^T$ 奇异值分解使用方法

记住 $U A A^T U$ 在一起, 即 $U$ 为 $m$ 阶方阵

1. 得到的矩阵 $C = AA^T$ 的特征值对角矩阵 $\text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$ 其中有 $r$ 个非零项, 所以将其写为:

$$\text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n) = \begin{bmatrix} \Sigma_{l \times l}^2 & O \\ O & O \end{bmatrix} \quad (32)$$

2. 求出每个 $\lambda_i$ 对应的特征向量,(零特征值的也求, 重根也求, 求 $n$ 个嘛)(每个特征值只求一个即可), 可得 $(\eta_1, \eta_2, \dots, \eta_n)$ , 由于谱分解的定律我们可以得到:

$$\begin{aligned}
 U^H A A^T U &= \begin{bmatrix} \Sigma_{l \times l}^2 & O \\ O & O \end{bmatrix} \\
 U &= (\eta_1, \eta_2, \dots, \eta_n)
 \end{aligned}$$

取 $U_{n \times n}$ 的前 $r$ 列构成矩阵 $U_1$ 可以得到:  $U = [U_{1(n \times l)} | U_{2(n \times n-l)}]$

3. 令  $V_1 = (U_1^H A \Sigma^{-1})^H$  可得  $V = [V_1 | V_2]$  让其中  $V_2$  为随意列只要保证  $V$  正交即可:

4. 则:

$$U^H A V = \begin{bmatrix} \Sigma & O \\ O & O \end{bmatrix} \quad (33)$$

## 8.3 奇异值分解的定理与应用

### 8.3.1 定理

1.  $A = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^H + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^H + \dots + \sigma_n \mathbf{u}_n \mathbf{v}_n^H$
2.  $N(A) = L(\mathbf{v}_{r+1}, \mathbf{v}_{r+2}, \dots, \mathbf{v}_{r+n})$
3.  $R(A) = L(\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n)$

### 8.3.2 应用

数据复原上我们有了一些数据, 就是数据矩阵上的一些点是已知  $X_{ij}$ ,  $(i, j) \in \mathcal{A}$  的但是矩阵中存在未知的元素在里面。

我们要求已知点被还原时满足

## Part II

## 矩阵的特征值的重要性质:

1. 其中  $\lambda(A)$  代表  $A$  的特征值

2.

$$\lambda(B) = 1/\lambda(B^{-1}), \lambda(A^T A) = \lambda(AA^T)$$

3. 即  $A$  的特征值是  $\lambda$ , 则  $A^{-1}$  的特征值是  $\frac{1}{\lambda}$

4. 且  $A^k$  的特征值为  $\lambda^k$

5.  $AA^T$  的非零特征值为  $A^T A$  的非零特征值,  $AB$  与  $BA$  的非零特征值一样的, 又因为  $\text{tr}(AB) = \text{tr}(BA)$  所以非零值不仅一样重数也一样。

推导

$$A\mathbf{x} = \lambda\mathbf{x}, \quad B\mathbf{x} = \beta\mathbf{x}$$

$$BA\mathbf{x} = B\lambda\mathbf{x} = \lambda B\mathbf{x} = \lambda\beta\mathbf{x}$$

$$AB\mathbf{x} = A\beta\mathbf{x} = \beta A\mathbf{x} = \beta\lambda\mathbf{x}$$